

# Clasificarea Imaginilor RMN ale Creierului

## Etapa 1

Alexandru Licuriceanu  
alicuriceanu@stud.acs.upb.ro

### 1 Cerința 2

Pentru a permite o evaluare robustă a modelului, am implementat o funcție care împarte setul de date de antrenare în două subseturi: 80% pentru antrenare și 20% pentru validare.

Lungimea setului de antrenare și testare, înainte de împărțire:

Train size: 2870, Test size: 394

Lungimea setului de antrenare, validare și testare după împărțire:

Train size: 2296, Val size: 574, Test size: 394

### 2 Cerința 3

Pentru această cerință, am realizat grafice de bare pentru fiecare dintre cele 3 dataset-uri, de unde au reieșit următoarele rezultate:




Figure 1: Distribuția claselor în seturile de date.

Am analizat distribuția claselor și am observat faptul că seturile de date de antrenare și validare au clase echilibrate, cu excepția clasei no\_tumor, care

este sub-reprezentată. Setul de date de test are clasele oarecum echilibrate, iar discrepanța dintre numărul de exemple din fiecare clasă este mai mică decât cea de la seturile de date de antrenare și validare.

Aceast lucru poate pune dificultăți în clasificarea imaginilor din no\_tumor, deoarece modelul tinde să învețe mai bine din clasele cu mai multe exemple.

O modalitate prin care se poate remedia această problemă poate fi generarea de imagini suplimentare folosind augmentari precum rotația, oglindirea, modificarea contrastului, sau a luminozității, măbind volumul de date pentru clasa no\_tumor.

O altă modalitate poate fi ajustarea loss function-ului prin atribuirea unei ponderi mai mari erorilor asociate clasei no\_tumor. Acest lucru va face ca modelul să penalizeze mai mult greșelile pentru această clasă, compensând dezechilibrul claselor.

### 3 Cerința 4

Pentru a înțelege mai bine cum arată și cum variază caracteristicile vizuale ale fiecărei categorii de tumoare, am extras și afișat 7 imagini aleatoare, din fiecare categorie:

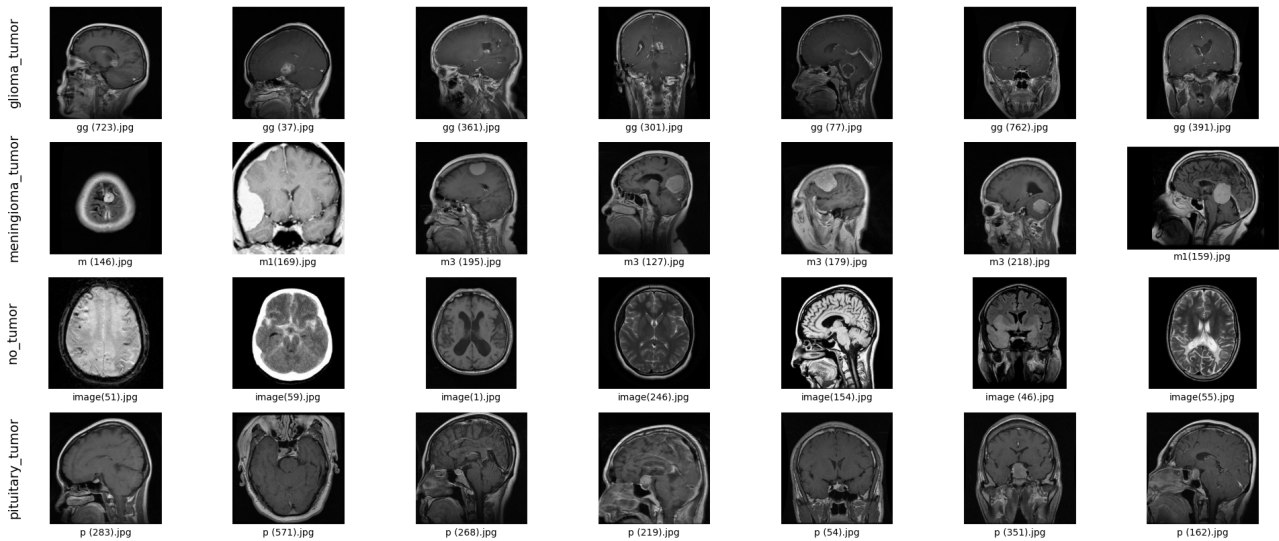


Figure 2: Exemple de imagini din fiecare clasă.

De aici se pot observa următoarele:

Tumorile gliomice prezintă o mare diversitate în ceea ce privește forma și textura și de obicei au forme neregulate. Marginile acestora sunt fie bine-delimitate, fie difuze. Poate apărea în orice regiune a creierului și de obicei apar mai întrecate pe imaginile RMN decât meningioamele sau tumorile pituitare.

Meningioamele sunt bine-delimitate, cu o formă regulată, sunt mai luminoase, tind să apară de obicei pe suprafața creierului, în apropierea oaselor

craniului, dar pot varia semnificativ ca dimensiune și localizare.

Tumorile pituitare sunt de dimensiuni reduse comparativ cu cele gliomice sau meningioamele, sunt localizate într-o regiune distinctă (glanda pituitară), au o formă ovală/rotundă cu margini bine-delimitate, dar pot prezenta o intensitate similară cu țesuturile adiacente.

În imaginile care nu conțin tumori, pot apărea structuri anatomice care prezintă caracteristici asemănătoare celor tumorale, ori zgomot sau artefacte care duc la clasificarea greșită.

## 4 Cerința 5

Pentru această cerință, am implementat diverse modificări pentru a asigura integritatea și consistența setului de date.

### 4.1 Verificarea numărului de canale ale imaginilor

Toate imaginile din setul de date au 3 canale de culoare, deci nu a fost necesară nicio operațiune pe imagini:




Figure 3: Numărul canalelor de culoare vs. numărul de imagini

```
Train Dataset channel distribution: {1: 0, 2: 0, 3: 2296}  
Validation Dataset channel distribution: {1: 0, 2: 0, 3: 574}  
Test Dataset channel distribution: {1: 0, 2: 0, 3: 394}
```

### 4.2 Verificarea dimensiunilor imaginilor

Imaginile din setul de date prezintă o multitudine de combinații de dimensiuni, cele mai multe fiind de 512x512 pixeli. Există diferențe și la raportul de lățime/înălțime, unde nu toate imaginile sunt 1:1. Când se va aplica transformarea de redimensionare la o rezoluție 1:1, imaginile care nu sunt pătrate vor fi distorsionate, astfel exista o posibilitate să se piardă informații în momentul în care va fi antrenată rețeaua neurală.

Train Dataset width distribution: min = 180, max = 1375  
Train Dataset height distribution: min = 198, max = 1446




Figure 4: Distribuția lățimilor și înălțimilor imaginilor din setul de antrenare înaintea redimensionării.

Pentru a uniformiza setul de date în vederea utilizării imaginilor într-o rețea neurală, am aplicat o transformare de redimensionare la 224x224 pixeli:

Resized Train Dataset width distribution: min = 224, max = 224  
Resized Train Dataset height distribution: min = 224, max = 224

### 4.3 Normalizarea imaginilor

Am verificat fiecare imagine și am constatat că toate imaginile sunt normalizate corespunzător:

Minimum Pixel Value: 0.0  
Maximum Pixel Value: 1.0

## 5 Cerința 6

Pentru a spori acuratețea și a ajuta clasificarea, am ales câteva operații de augmentare, după cum urmează:

- Blur Gaussian - Reducerea zgomotului din imagini pentru a elimina artefacte minore care pot perturba procesul de antrenare, astfel încât imaginile devin mai uniforme, iar modelul este mai puțin sensibil la variațiile nesemnificative, concentrându-se pe caracteristicile relevante ale tumorii.

- Random Rotation - Extinderea variabilității setului de date pentru a simula poziții diferite ale pacientului în timpul scanării, ajutând modelul să recunoască tumorile indiferent de orientarea lor ușor diferită.
- Normalization (Min-Max) - Asigurarea unei scalări uniforme a intensităților pixelilor pentru a îmbunătăți convergenței modelului în timpul antrenării.
- CLAHE - Îmbunătățește contrastul imaginii pentru a evidenția detaliile relevante din regiuni mai întunecate sau supraexpuse, astfel tumorile devin mai vizibile în imagini, ceea ce poate ajuta la extragerea feature-urilor de către model.
- Sobel Filter - Evidențiază marginile și conturul tumorilor, care pot fi caracteristici importante pentru clasificare. Modelul învață să se concentreze pe forma tumorii, ignorând variațiile de textură.
- Horizontal Flip - Creează imagini suplimentare prin inversare orizontală pentru a crește variabilitatea setului de date. Modelul devine robust la schimbările de orientare și nu mai depinde de poziționarea specifică a tumorii în imagine.
- Median Filter - Reduce zgomotul și a artefactele mici din imagini fără a afecta semnificativ marginile sau detaliile tumorilor, contrar blur-ului Gaussian. Efectul este o imagine mai curată care păstrează caracteristicile importante, îmbunătățind acuratețea în procesul de clasificare.




Figure 5: Augmentările alese și efectul acestora.

## 6 Cerința 7

Pentru modelul de rețea neurală de bază, am testat diferite arhitecturi, iar din experimente am ales următoarea configurație care a adus rezultate satisfăcătoare:

- Modelul utilizat - ResNet-18, care a adus rezultate bune, dar este un compromis între acuratețea de clasificare și resursele hardware utilizate.
- Loss function - Cross Entropy Loss, adecvată pentru problemele de clasificare multi-clasă.
- Optimizator - Adam, un optimizator adaptiv care ajustează rata de învățare pe baza gradientilor calculați și contribuie la o convergență rapidă a rețelei. Rata de învățare a fost setată la 0.001, însă va fi modificată automat de către optimizator.
- Numărul de epoci - 10, prin experimente am constatat că modelul nu mai învață nimic semnificativ după 10-12 epoci.
- Transformări - Redimensionarea imaginilor la 224x224 pixeli, Random Rotation (maxim 10 grade), Random Horizontal Flip cu probabilitatea de 0.5 și filtru de blur Gaussian cu probabilitatea de 0.5.

Așadar, rezultatele obținute cu modelul de bază sunt următoarele:

Class	Precision	Recall	F1-Score	Support
glioma_tumor	0.7600	0.1900	0.3040	100
meningioma_tumor	0.6538	0.8870	0.7528	115
no_tumor	0.5965	0.9714	0.7391	105
pituitary_tumor	0.9524	0.5405	0.6897	74
<b>Accuracy</b>			0.6675	394
<b>Macro avg</b>	0.7407	0.6472	0.6214	394
<b>Weighted avg</b>	0.7216	0.6675	0.6234	394

Table 1: Classification Report.




Figure 6: Matricea de confuzie.




Figure 7: Curbele de antrenare.